TALENDIG · MES 4 · DATA SCIENCE PARA IA

Práctica de Refuerzo

Limpieza de Datos — Clientes de un Gimnasio





Sistema	Python 3 + pandas (VS Code)
Archivo de datos	clientes_gimnasio.csv
Tiempo estimado	45 – 60 minutos, individual
Requisito previo	Clase de Limpieza de Datos (Pasos 1–5, Titanic)
Objetivo	Aplicar el mismo criterio de limpieza a un dataset nuevo

ANTES DE EMPEZAR

Cómo usar esta práctica

Esta práctica es individual — no es la continuación de la clase en vivo, es un refuerzo para que sigas afianzando lo que ya aprendiste con el Titanic, ahora aplicado a un dataset completamente nuevo. No vas a repetir el código de memoria: vas a tomar las mismas decisiones de limpieza, pero en un contexto distinto.

Vas a encontrar dos tipos de bloques:

> **PASOS CON PISTA**
> Te doy el código casi completo y la salida esperada, para que confirmes que tu razonamiento va bien encaminado.

> **PUNTOS DE DECISIÓN**
> Antes de ver cualquier código, vas a escribir en tus propias palabras qué harías con cada columna y por qué. Esto es a propósito: la forma más confiable de confirmar que entendiste el criterio (no solo la sintaxis) es explicarlo sin que nadie te lo dicte primero.

Trabaja en un archivo nuevo, por ejemplo `practica_gimnasio.py`, dentro de tu mismo repositorio del mes (`data-science-titanic-mes4`) o en una carpeta separada — no necesitas crear un repositorio nuevo para esto.

> **NOTA SOBRE TU VERSIÓN DE PANDAS**
> Vas a ver una línea al inicio del código — `pd.options.future.infer_string = False` — que quizás no reconozcas todavía. Solo cópiala tal cual; su propósito se explica en una clase más adelante. Sin ella, dependiendo de tu versión de pandas, podrías ver `str` en vez de `object` al revisar tipos de datos — el concepto es el mismo, pero por ahora mantenemos el mismo resultado que viste con el Titanic.

CONTEXTO

Sobre este dataset

Es un registro de clientes de un gimnasio con tres sedes en Santo Domingo (Naco, Piantini y Gazcue). Como cualquier dataset real, llega con información incompleta, algunos registros repetidos por error, y una columna numérica que en realidad es una categoría — los mismos tipos de problema que ya resolviste con el Titanic, pero sin que el código de esa clase te sirva para copiar y pegar directamente.

Columna	Significado
ClienteID	Número de identificación único de cada cliente
Nombre	Nombre completo del cliente
Edad	Edad en años
Plan	Tipo de membresía: 1 = Básico, 2 = Premium, 3 = VIP
Sucursal	Sede donde se inscribió: Naco, Piantini o Gazcue
DiasAsistidosMes	Días que asistió al gimnasio en el último mes
Email	Correo electrónico (el gimnasio empezó a pedirlo hace poco)

> **POR QUÉ EMAIL TIENE TANTOS NULOS**
> El sistema de inscripción del gimnasio empezó a pedir correo electrónico apenas hace unos meses. La mayoría de los clientes registrados antes de ese cambio simplemente no tienen ese dato — no es un error de captura, es un reflejo real de cuándo se empezó a recolectar esa información. (¿Te suena familiar? Es la misma lógica que usaste para explicar por qué `Cabin` tenía 77% de nulos en el Titanic.)

PASO 1

Cargar y explorar el dataset

Empieza exactamente igual que con el Titanic: cargar el archivo y mirarlo antes de tocar nada.

```
import pandas as pd

# Mantiene 'object' en vez de 'str' (se explica en una clase futura)
pd.options.future.infer_string = False

df = pd.read_csv("clientes_gimnasio.csv")

print("Forma del dataset:", df.shape)
print("\nPrimeras filas:")
print(df.head())
print("\nTipos de datos:")
print(df.dtypes)
```

Salida esperada:

```
Forma del dataset: (63, 7)

Primeras filas:
   ClienteID              Nombre  Edad  Plan Sucursal  DiasAsistidosMes               Email
0         56    Carlos Fernandez  64.0     1     Naco                 4  carlos56@gmail.com
1         17          Juan Reyes  47.0     3     Naco                29                 NaN
2          8    Yolanda Castillo  52.0     3     Naco                30                 NaN
3         25    Francisco Garcia  43.0     1     Naco                25                 NaN
4          7  Patricia Rodriguez   NaN     2     Naco                23                 NaN

Tipos de datos:
ClienteID             int64
Nombre               object
Edad                float64
Plan                  int64
Sucursal             object
DiasAsistidosMes      int64
Email                object
dtype: object
```

> **¿POR QUÉ 63 FILAS Y NO 60?**
> Vas a ver más adelante que el número real de clientes distintos es menor — algunas filas están repetidas por error. Por ahora solo confirma que el archivo cargó completo.

PASO 2

Diagnosticar los valores nulos

Igual que con Age, `Embarked` y `Cabin` en el Titanic: antes de decidir qué hacer, hay que saber cuántos nulos hay y en qué proporción.

```
print(df.isnull().sum())
print()
print((df.isnull().sum() / len(df) * 100).round(2))
```

Salida esperada:

```
ClienteID            0
Nombre               0
Edad                11
Plan                 0
Sucursal             2
DiasAsistidosMes     0
Email               47
dtype: int64

ClienteID            0.00
Nombre               0.00
Edad                17.46
Plan                 0.00
Sucursal             3.17
DiasAsistidosMes     0.00
Email               74.60
dtype: float64
```

PUNTO DE DECISIÓN

Antes de escribir código...

Tienes tres columnas con nulos: `Edad` (17.46%), `Sucursal` (3.17%) y `Email` (74.60%). Para cada una, responde antes de escribir cualquier código:

1. ¿Qué harías con los nulos de Edad y por qué?

Pista: piensa en qué tipo de dato es (numérico) y qué pasó con la edad en el Titanic.

2. ¿Qué harías con los nulos de Sucursal y por qué?

Pista: es una categoría con muy pocos nulos.

3. ¿Qué harías con los nulos de Email y por qué?

Pista: ¿realmente se puede "adivinar" un correo electrónico que nunca se registró?

PASO 3

Aplicar tu estrategia

Ahora sí, escribe el código. Si tu razonamiento del punto anterior fue distinto a lo que esperas ver aquí, vuelve a leer las pistas — pero intenta escribir tu propia versión antes de mirar la estructura de abajo.

```
# Edad: complete la linea con la estrategia que elegiste
df['Edad'] = df['Edad'].fillna( _____________ )

# Sucursal: complete la linea con la estrategia que elegiste
df['Sucursal'] = df['Sucursal'].fillna( _____________ )

# Email: complete la linea con la estrategia que elegiste
df = _____________

print("Nulos restantes:", df.isnull().sum().sum())
```

CÓMO CONFIRMAR QUE VAS BIEN

Si tu código quedó correcto, `df.isnull().sum().sum()` debe darte `0`, y `df.shape` debe mostrar 6 columnas en vez de 7 (porque una columna se eliminó por completo).

PASO 4

Eliminar duplicados

Mismo patrón que el Titanic: contar antes, eliminar, contar después.

```
print("Filas antes:", len(df))
df = df.drop_duplicates()
print("Filas después:", len(df))
```

ESTA VEZ SÍ VAS A VER UN CAMBIO

En el Titanic, “antes” y “después” daban el mismo número — nunca había duplicados reales, así que no pudiste comprobar el efecto de `drop_duplicates()`. Aquí sí hay clientes registrados dos veces por error. Ejecuta el código y compara los dos números — vas a ver la diferencia real por primera vez.

PASO 5

Verificar tipos de datos correctos

Una de las columnas numéricas en realidad es una categoría — igual que `Pclass` en el Titanic. ¿Cuál columna de este dataset tiene el mismo problema? (Pista: revisa el glosario del inicio — es la que tiene 3 valores fijos: 1, 2 y 3.)

```
df['_____________'] = df['_____________'].astype('category')

print(df.dtypes)
```

POR QUÉ IMPORTA

Si dejas esa columna como número, alguien podría calcular un “promedio de plan” sin que pandas avise que probablemente no tiene sentido — exactamente la misma razón por la que convertiste `Pclass` en categoría.

REFLEXIÓN FINAL

Tres preguntas para cerrar

Responde estas preguntas con tus propias palabras, después de haber ejecutado el código de los pasos anteriores — algunas piden que calcules algo extra para responderlas bien.

1. Mediana vs. promedio, con datos reales

Calcula la media y la mediana de Edad incluyendo a los clientes mayores de 85 años, y luego calcúlalas otra vez excluyéndolos. ¿Cuál de las dos medidas cambió más al quitar esos casos? ¿Por qué tiene sentido ese resultado?

2. Dos columnas, dos estrategias distintas

Sucursal tiene apenas 3.17% de nulos y Email tiene 74.60%. ¿Por qué la estrategia correcta no es la misma para ambas, aunque las dos sean columnas de texto?

3. Mirando hacia adelante

Si este gimnasio quisiera más adelante predecir qué clientes están en riesgo de cancelar su membresía, ¿qué precaución tomarías con los datos que acabas de limpiar antes de usarlos para eso?

CIERRE

Autoevaluación antes de entregar

Marca cada punto antes de dar por terminada la práctica. Si algo no se cumple, regresa al paso correspondiente — no necesitas que nadie te lo señale primero.

- [ ] df.shape final muestra (60, 6) — sin duplicados y sin la columna Email
- [ ] df.isnull().sum().sum() da 0
- [ ] Plan aparece como category en df.dtypes, no como int64
- [ ] Puedes explicar en una frase por qué Sucursal y Email tuvieron tratamientos distintos
- [ ] Respondiste las 3 preguntas de reflexión con tus propias palabras

Práctica preparada para Talendig · Mes 4 · Data Science para IA · Junio 2026